

LLM tarpusavio sąveikos ir argumentavimo simuliacija

Kursinis darbas

Mantvydas Skruodys

Darbo vadovas: prof. dr. Aistis Raudys



Tikslas ir motyvacija

- Ar keli DKM agentai, debatuodami gražina geresnį, labiau subalansuotą atsakymą nei vienas modelis?
- Ar **mažesnis** modelis debatų sistemoje gali pasiekti panašius rezultatus kaip **didesnis** gilaus mąstymo modelis?
- **Tikslas:** realizuoti DKM debatų sistemą ir palyginti jos išvestį su keturiomis kitomis sistemomis.


Daugiaagentis debatas gerina faktinį tikslumą ir argumentų įvairovę [1, 2].

Penkios lyginamos sistemos

Savo debatų sistemą (A) lyginu su keturiomis vieno modelio sistemomis:

Sistema	Aprašymas	Modelis
A	Debatų sistema	Qwen 2.5 14B
B	Vienas modelis	Qwen 2.5 14B
C	Vienas modelis + užklausa	Qwen 2.5 14B
D	Gilaus mąstymo modelis	QwQ-32B
E	Gilaus mąstymo modelis + užklausa	QwQ-32B

Sistema A: debatų architektūra




Visi vaidmenys – tas pats Qwen 2.5 14B modelis, atskirti sistemos užklausomis.

Vertinimo metodika

- Vertintojas: **Claude** (DKM kaip vertintojas) – visas išvestis įvertina vienodai.
- Penkios metrikos sujungiamos į kompozitinį balą:

Metrika	Svoris
Argumentų aprėptis	35–40 %
Argumentų gylis	20 %
Subalansuotas vaizdavimas	20 %
Atitikimas temai	15–20 %
Faktinis nuoseklumas	10 % / N/A

Rezultatai (10 temų vidurkis)



- Sistema A laimėjo beveik visas 10 temų.
- 14B modelis debatuose pranoko 32B vieną modelį; užklausa padeda ($C > B$, $E > D$).

- Daugiagentė architektūra su mažesniu modeliu pranoko didesnį vieną modelį (9,6 prieš 8,6 ir 9,0).
- Komandų generavimas sukelia balanso problemą (aukštojo mokslo tema – balansas 8,2).
- Didesnis gylis gali sumažinti faktinį tikslumą (mirties bausmė – klaidingas Japonijos pavyzdys).
- **Ateityje:** balanso ir faktų tikrinimo žingsniai, keli skirtingi modeliai vienoje sistemoje.

Ačiū už dėmesį!

<https://github.com/Humantvis/Kursinis-darbas>

- [1] Yilun Du et al. “Improving Factuality and Reasoning in Language Models through Multiagent Debate”. In: *arXiv preprint arXiv:2305.14325* (2023). URL: <https://arxiv.org/abs/2305.14325>.
- [2] Tian Liang et al. “Encouraging Divergent Thinking in Large Language Models through Multi-Agent Debate”. In: *arXiv preprint arXiv:2305.19118* (2023). URL: <https://arxiv.org/abs/2305.19118>.
- [3] Lianmin Zheng et al. “Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena”. In: *Advances in Neural Information Processing Systems (NeurIPS)*. 2023. URL: <https://arxiv.org/abs/2306.05685>.

- [4] Chi-Min Chan et al. “ChatEval: Towards Better LLM-based Evaluators through Multi-Agent Debate”. In: *Proceedings of the International Conference on Learning Representations (ICLR)*. 2024. URL: <https://arxiv.org/abs/2308.07201>.
- [5] LM Studio. *OpenAI Compatibility Endpoints*. Žiūrėta 2025. 2024. URL: <https://lmstudio.ai/docs/developer/openai-compat>.