

VILNIAUS UNIVERSITETAS
MATEMATIKOS IR INFORMATIKOS FAKULTETAS
INFORMATIKOS INSTITUTAS
INFORMATIKOS KATEDRA

Kursinis darbas

LLM tarpusavio sąveikos ir argumentavimo simuliacija
(Interaction and Argumentation Simulation between LLMs)

Atliko: studentas

Mantvydas Skruodys

Darbo vadovas:

prof. dr. Aistis Raudys

Vilnius
2026

Santrauka

Šiame kursiniame darbe realizuota ir įvertinta daugiagentė DKM debatų sistema (*LLMDebat*), kurioje keli dirbtinio intelekto agentai simuliuoja debatą pasirinkta tema ir paruošia galutinį atsakymą.

Sistema palyginta su keturiomis kitomis sistemomis:

- vieno modelio atsakymu
- vieno modelio atsakymu su daugiaperspektyvia užklausa
- giliai mąstančio modelio atsakymu
- giliai mąstančio modelio atsakymu su daugiaperspektyvia užklausa

Eksperimentas atliktas su dešimčia skirtingų debatinių temų. Sistemų išvestys vertintos naudojant DKM kaip vertintoją pagal penkias metrikas:

- argumentų aprėptį
- argumentų gylį
- subalansuotą vaizdavimą
- atitikimą temai
- faktinį nuoseklumą

Rezultatai parodė, kad debatų sistema (A) pasiekė aukščiausią vidurkį (9,6) per visas dešimt temų – tai net geriau nei dvigubai didesnis giliai mąstantis modelis QwQ-32B (8,6 ir 9,0).

Silpniausias rezultatas gautas vieno modelio sistemoje (7,3).

Tyrimas parodė, kad daugiagentė sistema su mažesniu modeliu gali pranokti didesnę vieno modelio sprendimą argumentų aprėpties ir įvairovės požiūriu.

Summary

In this course work, a multi-agent LLM debate system (*LLMDebateai*) was implemented and evaluated, in which several artificial intelligence agents simulate a debate on a given topic and give a final answer.

The system was compared against four other systems:

- single model response
- single model response with multi-perspective prompting
- deep thinking model response
- deep thinking model response with multi-perspective prompting

The experiment was done with ten different debate topics. System outputs were evaluated using an LLM as an evaluator based on five metrics:

- argument coverage
- argument depth
- balanced representation
- relevance to the topic
- factual consistency

Results showed that the debate system (A) got the highest average score (9.6) for all ten topics – this is even better than the twice-as-large deep thinking model QwQ-32B (8.6 and 9.0).

Single model system got the weakest result (7.3).

The study demonstrated that a multi-agent system using a smaller model can outperform a larger single-model solution in terms of argument coverage and diversity.

Turinys

Santrauka	1
Summary	2
Sąvokų apibrėžimai	4
Išvadas	5
1. Susijusių darbų apžvalga	6
1.1. Daugiagentės debatų sistemos	6
1.2. DKM kaip vertintojas	6
2. Sistemos projektavimas	7
2.1. Bendras architektūros aprašas	7
2.2. Komandų generavimo modulis	7
2.3. Kalbėjimo grafiko struktūra	7
2.4. Kalbėtojo užklausa	8
2.5. Išvesties generavimas	9
2.6. Vieno modelio sistema	10
3. Vertinimo metodika	11
3.1. DKM kaip vertintojas	11
3.2. Penki vertinimo kriterijai	11
3.2.1. Argumentų aprėptis	11
3.2.2. Argumentų gylis	11
3.2.3. Subalansuotas vaizdavimas	12
3.2.4. Atitikimas temai	12
3.2.5. Faktinis nuoseklumas	12
3.3. Vertinimo išvesties formatas	12
4. Testavimo procedūra	13
4.1. Išvesties generavimas	13
4.2. Vertinimo vykdymas	13
4.3. Programų kodai ir eksperimento išvestys	13
4.4. Testavimo schema	13
5. Eksperimentas	15
5.1. Eksperimento konfigūracija	15
5.2. Penkios lyginamos sistemos	16
5.3. Eksperimento rezultatai	16
5.3.1. Tema 1: Social media does more harm than good to society	16
5.3.2. Tema 2: Climate change requires immediate and radical government intervention	16
5.3.3. Tema 3: Universal basic income should be implemented globally	17
5.3.4. Tema 4: Capital punishment should be abolished worldwide	17
5.3.5. Tema 5: Genetic engineering of human embryos should be permitted	18
5.3.6. Tema 6: Developed nations have a moral obligation to accept climate refugees	18
5.3.7. Tema 7: Surveillance technology makes society safer	18
5.3.8. Tema 8: Higher education should be free for everyone	19
5.3.9. Tema 9: Violent video games contribute to real-world aggression	19
5.3.10. Tema 10: Animals should have the same legal rights as humans	19
5.3.11. Bendrieji rezultatai	20
Išvados	21
Literatūra	22

Sąvokų apibrėžimai

DKM. Didelis kalbos modelis (angl. *Large Language Model*, LLM) – neuroninių tinklų modelis, apmokytas dideliais teksto duomenų rinkiniais, kad galėtų generuoti tekstą.

Debatų sistema. Sistema, kurioje keli DKM agentai simuliuoja debatą tam tikra tema.

Giliai mąstantis modelis. DKM, kuris prieš grąžindamas atsakymą, iš pradžių padaro grandininį samprotavimą (angl. *chain-of-thought reasoning*). Tai reiškia, jis generuoja mintis, išbando skirtingus variantus, gali save pataisyti.

DKM kaip vertintojas. Vertinimas, kur kitas DKM vertina generuotus atsakymus pagal kriterijus.

Kompozitinis balas. Galutinis balas, kuris yra gaunamas susumavus visus kriterijus su svoriais.

Išvadas

Dirbtinis intelektas per pastaruosius metus stipriai patobulėjo. Tai leidžia kurti sistemas, kurios gali ne tik atsakyti į klausimus, bet ir simuliuoti sudėtingą debatą.

Šiame darbe bus nagrinėjama daugiagentė debatų sistema, kurioje keli DKM agentai gina skirtingas pozicijas ir tarpusavyje argumentuoja. Tokia sistema priverčia modelius žiūrėti į klausimą iš daugiau perspektyvų ir taip sukurti geresnius apibendrinimus nei vienas modelis.

Taip pat šiame darbe bus tikrinama, ar šiuo būdu yra galima su mažesniu modeliu pasiekti panašios kokybės atsakymus kaip ir su didesniu gilaus mąstymo modeliu.

Darbo tikslas – realizuoti ir įvertinti DKM debatų sistemą, palyginti jos išvestį su keturiais kitais scenarijais ir nustatyti debatų sistemos veikimo kokybę.

Uždaviniai:

1. Suprojektuoti daugiagentę debatų sistemą.
2. Realizuoti vieno modelio sistemą su valdymo vėliavėlėmis skirtingiems veikimo režimams.
3. Atlikti eksperimentus su dešimčia skirtingų temų ir palyginti visų sistemų išvestis.
4. Aptarti rezultatus ir tobulinimo galimybes.

Lyginamos penkios sistemos:

- A – daugiagentė debatų sistema;
- B – vieno modelio bazinė sistema;
- C – vieno modelio sistema su daugiaperspektyvia užklausa;
- D – gilaus mąstymo modelis;
- E – gilaus mąstymo modelis su daugiaperspektyvia užklausa.

DKM debatų sistemos yra aktyviai nagrinėjamos: [DLT⁺23] ir [LHJ⁺23] rodo, kad daugiagentis debatas gali pagerinti faktinį tikslumą ir argumentų įvairovę. Šis kursinis darbas prisideda prie šios temos nagrinėjimo.

1. Susijusių darbų apžvalga

1.1. Daugiagentės debatų sistemos

Du ir kt. [DLT⁺23] parodė, kad DKM agentų tarpusavio diskusija (angl. *society of mind*) pagerina faktinį tikslumą ir atsakymo kokybę.

Liang ir kt. [LHJ⁺23] tyrinėjo, kaip skirtingi agentai gali taisyti vieni kitus.

Chan ir kt. [CCS⁺24] suprojektavo *ChatEval* sistemą, kuri naudoja modelių debatus atsakymams vertinti.

1.2. DKM kaip vertintojas

Zheng ir kt. [ZCS⁺23] sukūrė MT-Bench ir Chatbot Arena platformas, kuriose GPT-4 naudojamas kaip vertintojas vertinti dialogų kokybę. Jie parodė, kad DKM vertintojų sprendimai stipriai sutampa su žmonių vertinimais.

2. Sistemos projektavimas

2.1. Bendras architektūros aprašas

LLMDebate sistema realizuota naudojant Python kalbą. Programa naudoja lokaliai paleistus DKM per LM Studio teikiamą *OpenAI* suderinamo formato REST sąsają (<http://localhost:1234/v1>) [LM 24].

Pagrindiniai architektūriniai sprendimai:

1. **Vienas modelis** – tas pats `MODEL_ID` naudojamas visų komandų kalbėtojams, komandų generatoriui ir sukurti galinį sistemos išvedimą. Vaidmenys atskiriami sistemos užklausomis (angl. *system prompt*).
2. **Komandų generavimas** – funkcija `generate_teams()` kiekvienai temai nusprendžia kiek reikia skirtingų komandų su skirtingais požiūriais.
3. **Kalbėjimo eiliškumas** – komandos kalba viena po kitos, naujas kalbėtojas gauna visą debatų įrašą ir gali papildyti, paneigti, argumentuoti prieš anksčiau sakytus argumentus.
4. **Išvestis** – galutinis atsakymas paruošiamas atskirai, modelis gauna visą debatų įrašą, padaro debato santrauką ir grąžina galutinį debatų sistemos atsakymą.

2.2. Komandų generavimo modulis

Vietoj dviejų iš anksto žinomų pusių (už/prieš), sistema pati nusprendžia, kiek skirtingų perspektyvų tema turi. Iškviečiamas modelis su žema temperatūra (`ANALYSIS_TEMPERATURE = 0.5`), kuris grąžina JSON masyvą:

Listing 1: Komandų generavimo sistemos užklausa

```
"You are a debate organiser. "  
"Analyse the topic and identify all distinct perspectives. "  
"A topic does not always have two sides. "  
"Do not invent sides that do not have a meaning to exist. "  
"Return ONLY a JSON array. Each item must have 'name' and 'stance'  
  keys."
```

Gautas JSON tekstas išvalomas nuo galimų Markdown žymų ir nuskaitomas (`json.loads`). Jei nuskaitymas nepavyksta arba trūksta privalomų laukų, funkcija išmeta klaidą.

2.3. Kalbėjimo grafiko struktūra

Funkcija `build_speaking_schedule()` sukuria kalbėjimo tvarką. Kiekvienai komandai paskiriami `SPEAKERS_PER_TEAM` kalbėtojai, pirmas kalbėtojas – atidarymo, paskutinis – uždarymo.

2.4. Kalbėtojo užklausa

Kalbėtojai argumentus turi remti įrodymais ar statistika. Antras arba dar vėlesni kalbėtojas turi sugalvoti bent du naujus argumentus, kurių dar nebuvo minėta debatuose.

Listing 2: Kalbėtojo sistemos užklausa

```
system_prompt = (  
    f"You are a debater representing {team['name']}. "  
    f"You are arguing {team['stance']} the proposition: '{topic}'. "  
    "Speak only for yourself. "  
    "You may rebut arguments made by other teams. "  
    "Support every argument with specific evidence, statistics,  
        named studies, "  
    "or concrete real-world examples where possible. "  
    "Cover as many distinct arguments for your position as possible.  
    "  
    "You must respond in English only, regardless of your default  
        language."  
)  
# Speaker 1 addition:  
"You are the opening speaker. "  
"Introduce your team's core position and lay out your main arguments  
    . "  
# Speaker > 1 addition:  
"You MUST introduce at least two new arguments that have not yet  
    been raised "  
"by anyone in this debate. Do not simply rebut or repeat what has  
    already been said. "  
# Last speaker addition:  
"You are the closing speaker. "  
"After your new arguments, briefly summarise your team's overall  
    position. "
```

Kalbėtojo vartotojo užklausoje perduodamas visas iki tol sukauptas debatų įrašas, todėl kiekvienas kalbėtojas gali reaguoti į ankstesnius argumentus.

2.5. Išvesties generavimas

Modeliui debatų įrašas perduodamas tik kaip pagalbinė medžiaga – analizuotojas privalo sava-rankiškai identifikuoti visus svarbius argumentus iš visų pusių, nepriklausomai nuo to, ar jie buvo paminėti debatuose.

Listing 3: Išvesties užklausa

```
system_prompt = (  
    f"You are an expert analyst reviewing a multi-team debate on: '{  
        topic}'". "  
    f"The teams were: {team_list}". "  
    "Your job is to write a comprehensive, well-structured answer to  
        the topic question. "  
    "You MUST independently identify and include ALL major arguments  
        on ALL sides, "  
    "whether or not the debaters raised them. "  
    "For each argument, provide specific evidence, concrete examples  
        , or statistics. "  
    "Structure your answer with clear sections covering each  
        distinct perspective. "  
    "Do not pick a side. "  
    "You must respond in English only, regardless of your default  
        language."  
)
```

2.6. Vieno modelio sistema

Palyginimui sukurta `runSingleModel.py` programa su dviem vėliavėlėmis:

Listing 4: Valdymo vėliavėlės vieno modelio sistemoje

```
DEEP_THINKING = True    # Naudoti giliai mstant model
PROMPTED = True         # Pridėti daugiaperspektyvi klaus
```

Šios vėliavėlės suformuoja keturis skirtingus veikimo režimus (B, C, D, E sistemas) ir automatiškai išveda atsakymą į atitinkamus aplankus:

- `vieno_modelio_isvestis`,
- `vieno_modelio_isvestis_prompted`,
- `vieno_modelio_isvestis_giliaimastymo`,
- `vieno_modelio_isvestis_giliaimastymo_prompted`.

variante su papildoma užklausa (C, E) klausimas papildomas daugiaperspektyvio samprotavimo nurodymu:

Listing 5: Vieno modelio vartotojo užklausa

```
user_prompt = f"What is the answer to: '{TOPIC}'."
if PROMPTED:
    user_prompt += " Think of arguments from multiple perspectives
                   before giving a conclusion."
```

3. Vertinimo metodika

3.1. DKM kaip vertintojas

Sistemų išvestis vertina didesnis DKM, kuris turi parengtus vertinimo kriterijus. Kaip vertintojas naudojamas Claude Sonnet 4.6 modelis per claude.ai puslapį. Taip galima greitai įvertinti didelį kiekį tekstų su vienodu vertinimu.

3.2. Penki vertinimo kriterijai

Vertinimo sistema apima penkias metrikas:

1 lentelė. Vertinimo metrikų svoriai

Metrika	Svoris (faktiniai duomenys)	Svoris (be faktų)
Argumentų aprėptis	35 %	40 %
Argumentų gylis	20 %	20 %
Subalansuotas vaizdavimas	20 %	20 %
Aktualumas ir darna	15 %	20 %
Faktinis nuoseklumas	10 %	N/A

3.2.1. Argumentų aprėptis

Ši metrika matuoja, kiek skirtingų argumentų sistema apima, lyginant su sistema, kuri apėmė daugiausiai argumentų.

$$\text{balas} = \frac{\text{apimtų argumentų skaičius}}{\max(\text{apimtų argumentų skaičiai per visas sistemas})} \times 10$$

3.2.2. Argumentų gylis

Kiekvienas apimtas argumentas yra įvertinamas:

- 3 – argumentas paremtas konkrečiais įrodymais, statistika ar pavyzdžiais;
- 2 – argumentas paaiškintas keliais sakiniais su samprotavimais;
- 1 – argumentas paminėtas paviršutiniškai.

$$\text{gylis balas} = \frac{\text{vidurkis}}{3} \times 10$$

3.2.3. Subalansuotas vaizdavimas

Yra naudojama normalizuotoji Šenono entropija. Vertintojas nustato k skirtingų perspektyvų, skaičiuoja argumentus kiekvienai perspektyvai n_i ir apskaičiuoja:

$$H = - \sum_{i=1}^k p_i \log_2(p_i), \quad H_{\max} = \log_2(k), \quad \text{balanso rodiklis} = \frac{H}{H_{\max}}$$

3.2.4. Atitikimas temai

Ši metrika vertinama 0–10 skalėje:

- 9–10 – atsakymas visiškai atitinka temą;
- 7–8 – atsakymas dažniausiai atitinka temą;
- 5–6 – atsakymas iš dalies atitinka temą;
- 3–4 – atsakymas silpnai susijęs su tema;
- 0–2 – atsakymas neatitinka temos.

3.2.5. Faktinis nuoseklumas

Vertintojas randa faktinius teiginius (ne nuomones), suskirsto juos į tikslus, netikslus arba nepatikrinamus ir skaičiuoja:

$$\text{faktinis balas} = \frac{\text{tikslūs}}{\text{tikslūs} + \text{netikslūs}} \times 10$$

Nuomonėmis paremtoms temoms metrika gali būti priskiriama „N/A”.

3.3. Vertinimo išvesties formatas

Vertintojas grąžina rezultatus kaip Markdown lenteles. Taip rezultatai gali būti tiesiogiai skaitomi ir palyginami be papildomo apdorojimo.

Kiekvienai sistemai vertintojas pateikia:

- metrikų lentelę su visais penkiais balais ir kompozitiniu balu;
- perspektyvų pasiskirstymą su argumentų skaičiumi;
- apimtų ir neapimtų argumentų sąrašus;
- vieną sakinį apie atitikimą temai.

Visų penkių sistemų rezultatai parodomi palyginimo lentelėje.

4. Testavimo procedūra

4.1. Išvesties generavimas

Kiekvienai temai paleidžiama kiekviena iš penkių sistemų atskirai. Generavimas vykdomas lokaliai per LM Studio:

1. **Sistema A** – `LLMDebatei.py` paleidžiama su tema; debatų įrašas ir galutinė sintezė išsaugomi į `debatu_isvestis/`.
2. **Sistema B** – `runSingleModel.py` su `DEEP_THINKING = False, PROMPTED = False`; išvestis į `vieno_modelio_isvestis/`.
3. **Sistema C** – `runSingleModel.py` su `DEEP_THINKING = False, PROMPTED = True`; išvestis į `vieno_modelio_isvestis_prompted/`.
4. **Sistema D** – `runSingleModel.py` su `DEEP_THINKING = True, PROMPTED = False`; išvestis į `vieno_modelio_isvestis_giliaimastymo/`.
5. **Sistema E** – `runSingleModel.py` su `DEEP_THINKING = True, PROMPTED = True`; išvestis į `vieno_modelio_isvestis_giliaimastymo_prompted/`.

4.2. Vertinimo vykdymas

Vertinimui naudojamas Claude (claude.ai) kaip vertintojas. Kiekvienai temai Claude užklauiamas vieną kartą, užklausoje įkeliamos visų sistemų išvestys ir vertinimo instrukcijos (`grading instructions.txt`).

4.3. Programų kodai ir eksperimento išvestys

Programų kodai ir eksperimento išvestys prieinami GitHub repozitorijoje:

<https://github.com/Humantvis/Kursinis-darbas>

4.4. Testavimo schema

Bendras testavimo proceso srautas pavaizduotas lentelėje 2.

2 lentelė. Testavimo proceso schema

Žingsnis	Veiksmas	Įrankis	Išvestis
1	Paleisti 5 sistemas kiekvienai temai	LM Studio + Python	50 teksto failų
2	Surinkti visas 5 išvestis vienai temai	Rankinis	Grupė failų
3	Įkelti į Claude kartu su instrukcijomis	claude.ai	–
4	Gauti vertinimo lenteles	Claude	Markdown lentelės
5	Surinkti rezultatus visoms temoms	Rankinis	Suvestinė lentelė

5. Eksperimentas

5.1. Eksperimento konfigūracija

Eksperimentui pasirinkti du modeliai:

- **Qwen 2.5 14B Instruct** (Q4_K_M kvantizacija) – pagrindinis debatų sistemos ir vieno modelio scenarijaus modelis.
- **QwQ-32B** (Q4_K_M kvantizacija) – giliai mąstantis modelis naudojamas D ir E scenarijuose.

Modeliai paleisti per LM Studio. Kompiuterio ~14 GB laisvo VRAM leido patogiai naudoti Qwen 2.5 14B Instruct kaip pagrindinį modelį – didesni modeliai netelpa į VRAM atmintį ir turi dalį modelio laikyti kitur (RAM arba net disko atmintyje).

Eksperimento temos:

1. Social media does more harm than good to society
2. Climate change requires immediate and radical government intervention
3. Universal basic income should be implemented globally
4. Capital punishment should be abolished worldwide
5. Genetic engineering of human embryos should be permitted
6. Developed nations have a moral obligation to accept climate refugees
7. Surveillance technology makes society safer
8. Higher education should be free for everyone
9. Violent video games contribute to real-world aggression
10. Animals should have the same legal rights as humans

5.2. Penkios lyginamos sistemos

3 lentelė. Lyginamos sistemos

Sistema	Aprašymas	Modelis	Išvesties aplankas
A	Debatų sistema	Qwen 2.5 14B	debatu_isvestis
B	Vienas modelis	Qwen 2.5 14B	vieno_modelio_isvestis
C	Vienas modelis su papildoma užklausa	Qwen 2.5 14B	vieno_modelio_isvestis_ prompted
D	Giliai maštantis modelis	QwQ-32B	vieno_modelio_isvestis_ giliaimastymo
E	Giliai maštantis modelis su papildoma užklausa	QwQ-32B	vieno_modelio_isvestis_ giliaimastymo_prompted

5.3. Eksperimento rezultatai

Žemiau pateikti dešimties temų vertinimo rezultatai. Kiekvienai temai rodoma palyginamoji lentelė ir trumpas aptarimas.

5.3.1. Tema 1: Social media does more harm than good to society

4 lentelė. Socialinių tinklų temos rezultatai

Metrika	A	B	C	D	E
Argumentų aprėptis	9,3	5,3	6,7	10,0	7,3
Argumentų gylis	8,6	4,6	7,0	7,3	9,4
Subalansuotas vaizdavimas	9,8	10,0	10,0	10,0	9,2
Atitikimas temai	10,0	10,0	10,0	10,0	10,0
Faktinis nuoseklumas	9,5	10,0	10,0	10,0	10,0
Kompozitinis balas	9,4	7,3	8,2	9,5	8,8

Sistemos D ir A surinko didžiausius bendrus balus (9,5 ir 9,4). Sistema E pasiekė aukščiausią gylio balą (9,4), bet praleido daugiau argumentų.

5.3.2. Tema 2: Climate change requires immediate and radical government intervention

5 lentelė. Klimato kaitos temos rezultatai

Metrika	A	B	C	D	E
Argumentų aprėptis	10,0	6,9	8,5	10,0	10,0
Argumentų gylis	8,5	4,1	7,3	8,2	9,0
Subalansuotas vaizdavimas	9,2	9,9	10,0	9,2	9,5
Atitikimas temai	10,0	10,0	10,0	10,0	10,0
Faktinis nuoseklumas	10,0	10,0	10,0	10,0	10,0
Kompozitinis balas	9,5	7,7	8,9	9,5	9,7

Ši tema pasiekė aukščiausius įvertinimus per visas sistemas, tai reiškia, kad tema buvo ganėtinai paprasta ir visos sistemos galėjo atsakyti kokybiškai. Šioje temoje Sistema E pasiekė geresnius rezultatus negu kitos sistemos (9,7). Sistema A, D ir E pasiekė aukščiausius aprėpties balus, taip įvyko, nes visos sistemos rado tokį patį skaičių argumentų.

5.3.3. Tema 3: Universal basic income should be implemented globally

6 lentelė. Universalinių bazinių pajamų temos rezultatai

Metrika	A	B	C	D	E
Argumentų aprėptis	10,0	5,9	7,6	7,1	8,8
Argumentų gylis	8,4	6,0	6,4	6,7	7,3
Subalansuotas vaizdavimas	9,4	9,7	8,4	9,4	8,8
Atitikimas temai	10,0	10,0	10,0	10,0	10,0
Faktinis nuoseklumas	10,0	10,0	10,0	10,0	10,0
Kompozitinis balas	9,6	7,7	8,1	8,2	8,8

Sistema A su šia tema aiškiai atsiskyrė nuo visų kitų. Trijų komandų padalinimas (UŽ, PRIEŠ, sąlyginė forma) leido sugalvoti daugiau skirtingų argumentų.

5.3.4. Tema 4: Capital punishment should be abolished worldwide

7 lentelė. Mirties bausmės temos rezultatai

Metrika	A	B	C	D	E
Argumentų aprėptis	10,0	5,0	6,4	7,1	7,9
Argumentų gylis	8,3	6,2	6,7	8,7	7,6
Subalansuotas vaizdavimas	9,8	9,8	9,2	8,8	8,5
Atitikimas temai	10,0	10,0	10,0	10,0	10,0
Faktinis nuoseklumas	7,5	10,0	10,0	10,0	10,0
Kompozitinis balas	9,4	7,5	7,9	8,5	8,5

Sistema A pasiekė aukščiausią bendrą balą (9,4), tačiau faktinis tikslumas nebuvo 10,0 – modelis naudojo Japoniją kaip abolicionistinį pavyzdį, kas yra neteisinga. Sistema D pasiekė aukščiausią gylio balą (8,7) iš visų ne-debatų sistemų.

5.3.5. Tema 5: Genetic engineering of human embryos should be permitted

8 lentelė. Genetinės inžinerijos temos rezultatai

Metrika	A	B	C	D	E
Argumentų aprėptis	10,0	5,3	5,3	7,1	7,1
Argumentų gylis	7,8	5,2	6,7	8,3	8,1
Subalansuotas vaizdavimas	10,0	7,6	9,9	9,2	9,8
Atitikimas temai	10,0	10,0	10,0	10,0	10,0
Faktinis nuoseklumas	10,0	10,0	10,0	10,0	10,0
Kompozitinis balas	9,6	6,9	7,7	8,5	8,6

Matosi aiškus skirtumas tarp Sistemos A ir kitų keturių. Sistema A pasiekė 10,0 balą visose metrikose išskyrus argumentų gilumą, tai parodo, kad modelis balansuotai apmąstė daugiausiai argumentų.

5.3.6. Tema 6: Developed nations have a moral obligation to accept climate refugees

9 lentelė. Klimato pabėgėlių temos rezultatai

Metrika	A	B	C	D	E
Argumentų aprėptis	10,0	5,0	4,3	6,4	8,6
Argumentų gylis	8,3	6,7	6,7	7,8	8,1
Subalansuotas vaizdavimas	10,0	9,8	10,0	9,9	9,8
Atitikimas temai	10,0	10,0	10,0	10,0	10,0
Faktinis nuoseklumas	10,0	10,0	10,0	10,0	10,0
Kompozitinis balas	9,7	7,6	7,3	8,3	9,1

Sistema C šioje temoje gavo blogesnę įvertinimą negu Sistema B, tai parodo, kad net su papildoma užklausa modelis gali grąžinti blogesnę atsakymą.

5.3.7. Tema 7: Surveillance technology makes society safer

10 lentelė. Stebėjimo technologijų temos rezultatai

Metrika	A	B	C	D	E
Argumentų aprėptis	10,0	4,0	8,0	7,3	10,0
Argumentų gylis	8,7	5,6	6,4	7,9	8,2
Subalansuotas vaizdavimas	9,0	10,0	9,2	9,4	8,8
Atitikimas temai	10,0	10,0	10,0	10,0	10,0
Faktinis nuoseklumas	10,0	10,0	10,0	10,0	10,0
Kompozitinis balas	9,5	7,0	8,4	8,5	9,4

Sistema A ir Sistema E gavo labai panašius rezultatus, bet debatai vis tiek lenkia visas kitas sistemas.

5.3.8. Tema 8: Higher education should be free for everyone

11 lentelė. Aukštojo mokslo temos rezultatai

Metrika	A	B	C	D	E
Argumentų aprėptis	10,0	5,0	8,1	6,9	8,1
Argumentų gylis	9,6	6,3	6,4	7,6	7,9
Subalansuotas vaizdavimas	8,2	10,0	10,0	9,9	10,0
Atitikimas temai	10,0	10,0	10,0	10,0	10,0
Faktinis nuoseklumas	10,0	10,0	10,0	10,0	10,0
Kompozitinis balas	9,6	7,5	8,6	8,4	8,9

Sistema A pasiekė aukščiausią gylio balą iš visų dešimties temų (9,6), tačiau balansas (8,2) yra mažiausias iš visų temų – trečioji komanda papildino PRO pusę ir taip pakeitė pusiausvyrą.

5.3.9. Tema 9: Violent video games contribute to real-world aggression

12 lentelė. Smurtinių vaizdo žaidimų temos rezultatai

Metrika	A	B	C	D	E
Argumentų aprėptis	10,0	2,2	3,3	5,0	7,8
Argumentų gylis	9,6	6,7	6,7	7,8	8,3
Subalansuotas vaizdavimas	9,7	10,0	9,2	10,0	10,0
Atitikimas temai	10,0	10,0	10,0	10,0	10,0
Faktinis nuoseklumas	10,0	10,0	10,0	10,0	10,0
Kompozitinis balas	9,9	6,6	6,8	7,8	8,9

Smurtinių vaizdo žaidimų tema davė ryškiausią skirtumą tarp sistemų – Sistema A pasiekė aukščiausią balą per visą eksperimentą (9,9), o Sistemos B ir C – žemiausius aprėpties rezultatus (2,2 ir 3,3). Dėl šios priežasties ši tema gavo mažiausią bendrą įvertinimų vidurkį visoms temoms.

5.3.10. Tema 10: Animals should have the same legal rights as humans

13 lentelė. Gyvūnų teisių temos rezultatai

Metrika	A	B	C	D	E
Argumentų aprėptis	10,0	5,3	7,3	8,0	7,3
Argumentų gylis	9,6	6,7	7,0	8,1	9,1
Subalansuotas vaizdavimas	9,6	8,9	8,4	9,5	9,9
Atitikimas temai	10,0	10,0	10,0	10,0	10,0
Faktinis nuoseklumas	10,0	10,0	10,0	10,0	10,0
Kompozitinis balas	9,8	7,5	8,1	8,8	8,9

Sistema A pasiekė dar vieną aukštą rezultatą (9,8), Sistema E, antroje vietoje, aplenkė kitas sistemas dėl aukščiausio gylio ir beveik tobulo balanso.

5.3.11. Bendrieji rezultatai

14 lentelė. Kompozitinių balų suvestinė per visas dešimt temų

Tema	A	B	C	D	E
Socialiniai tinklai	9,4	7,3	8,2	9,5	8,8
Klimato kaita	9,5	7,7	8,9	9,5	9,7
UBI	9,6	7,7	8,1	8,2	8,8
Mirties bausmė	9,4	7,5	7,9	8,5	8,5
Genetinė inžinerija	9,6	6,9	7,7	8,5	8,6
Klimato pabėgėliai	9,7	7,6	7,3	8,3	9,1
Stebėjimo technologijos	9,5	7,0	8,4	8,5	9,4
Aukštasis mokslas	9,6	7,5	8,6	8,4	8,9
Smurtiniai žaidimai	9,9	6,6	6,8	7,8	8,9
Gyvūnų teisės	9,8	7,5	8,1	8,8	8,9
Vidurkis	9,6	7,3	8,0	8,6	9,0

Sistema A laimėjo beveik visose dešimtyje temų su 9,6 vidurkiu, Sistema B buvo silpniausia (7,3), o Sistemos D ir E (8,6 ir 9,0), naudojančios galingesnę modelį (QwQ-32B), pasiekė panašius, bet žemesnius įvertinimus negu Sistema A.

Išvados

1. Daugiagentė debatų architektūra su mažesniu modeliu gavo geresnį rezultatą negu vienas didesnis modelis – Qwen 2.5 14B debatų sistemoje (vidurkis 9,6) aplenkė dvigubai didesnį QwQ-32B vieno modelio režime (8,6 ir 9,0), tai rodo, kad sistemos struktūra šioje užduotyje buvo svarbesnė už modelio dydį.
2. Užklausa pažiūrėti į temą iš skirtingų perspektyvų pagerino vieno modelio išvestį – Sistema C pasiekė 8,0, Sistema E pasiekė 9,0, lyginant su Sistema B (7,3) ir Sistema D (8,6) be papildomos užklauskos, tačiau visos keturios atsiliko nuo debatų sistemos (9,6).
3. Komandų generavimas leidžia sistemai prisitaikyti prie temos sudėtingumo, tačiau sukelia balanso problemą – aukštojo mokslo temoje trečioji komanda sustiprino PRO pusę ir debatų sistemos balanso balas pamažėjo iki 8,2.
4. Didesnis argumentų gylis gali sumažinti faktinį tikslumą – mirties bausmės temoje debatų sistema pasiekė aukščiausią bendrą balą (9,4), tačiau faktinio nuoseklumo balas buvo 7,5, nes modelis naudojo Japoniją kaip abolicionistinį pavyzdį, kas yra neteisinga.
5. Ateities darbai:
 - (a) balanso patikrinimo mechanizmas prieš debatus;
 - (b) faktų tikrinimo žingsnis sintezės modulyje, siekiant sumažinti pramanytus faktus;
 - (c) kitų modelių testavimas debatų sistemoje;
 - (d) kelių skirtingų modelių naudojimas vienoje debatų sistemoje.

Literatūra

- [CCS⁺24] Chi-Min Chan, Weize Chen, Yusheng Su, Jianxuan Yu, Wei Xue, Shanghang Zhang, Jie Fu ir Zhiyuan Liu. ChatEval: Towards Better LLM-based Evaluators through Multi-Agent Debate. *Proceedings of the International Conference on Learning Representations (ICLR)*, 2024. URL: <https://arxiv.org/abs/2308.07201>.
- [DLT⁺23] Yilun Du, Shuang Li, Antonio Torralba, Joshua B. Tenenbaum ir Igor Mordatch. Improving Factuality and Reasoning in Language Models through Multiagent Debate. *arXiv preprint arXiv:2305.14325*, 2023. URL: <https://arxiv.org/abs/2305.14325>.
- [LHJ⁺23] Tian Liang, Zhiwei He, Wenxiang Jiao, Xing Wang, Yan Wang, Rui Wang, Yujiu Yang, Zhaopeng Tu ir Shuming Shi. Encouraging Divergent Thinking in Large Language Models through Multi-Agent Debate. *arXiv preprint arXiv:2305.19118*, 2023. URL: <https://arxiv.org/abs/2305.19118>.
- [LM 24] LM Studio. OpenAI Compatibility Endpoints, 2024. URL: <https://lmstudio.ai/docs/developer/openai-compatible>. Žiūrėta 2025.
- [ZCS⁺23] Lianmin Zheng, Wei-Lin Chiang, Ying Sheng, Siyuan Zhuang ir k.t. Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena. *Advances in Neural Information Processing Systems (NeurIPS)*, 2023. URL: <https://arxiv.org/abs/2306.05685>.